Архитектура CLIP (ViT-B/32)

Radford et al. — ICML 2021

Image Encoder (ViT)

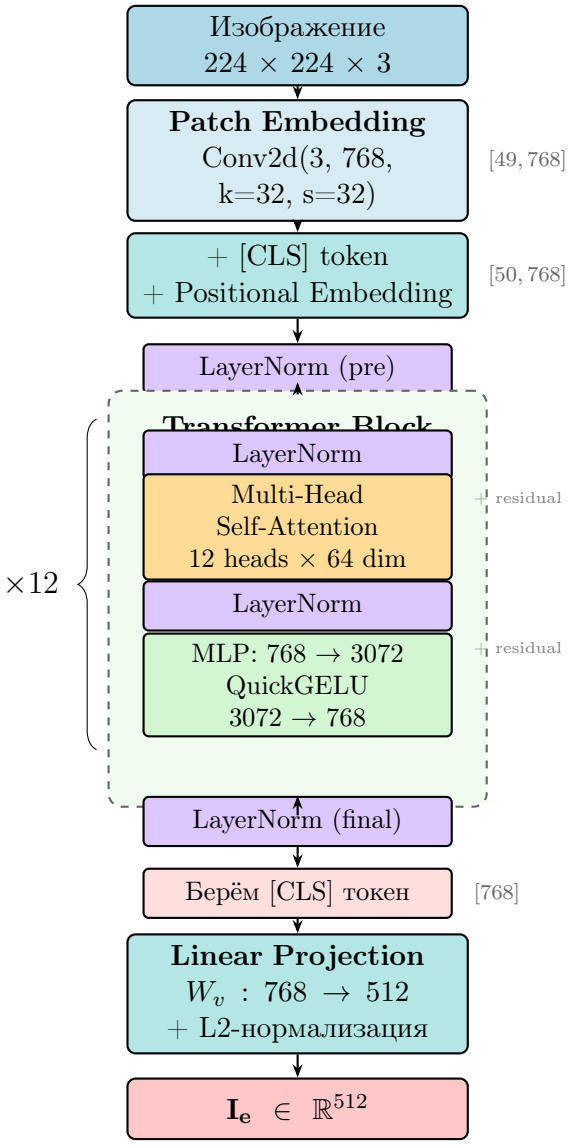

Text Encoder (Transformer)

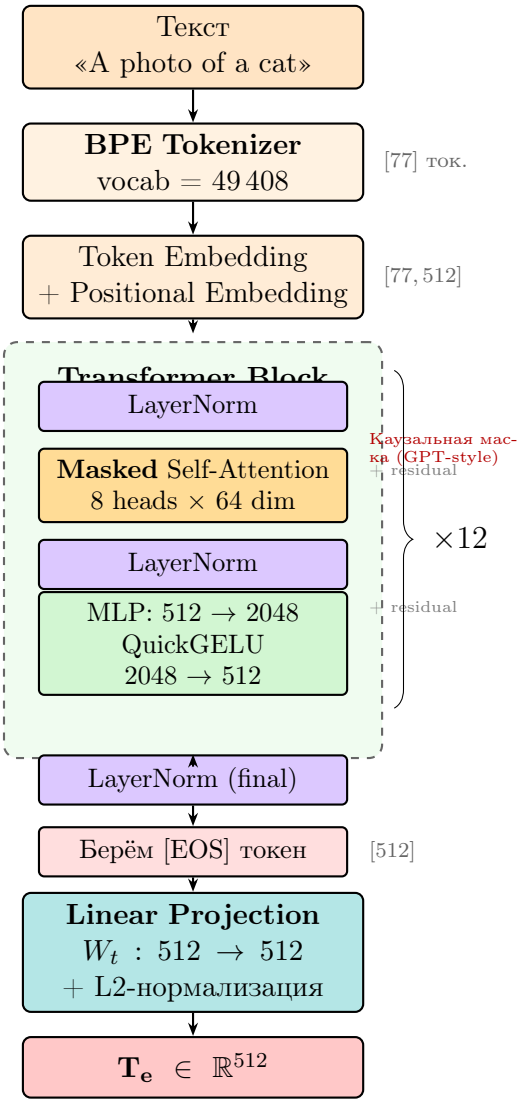

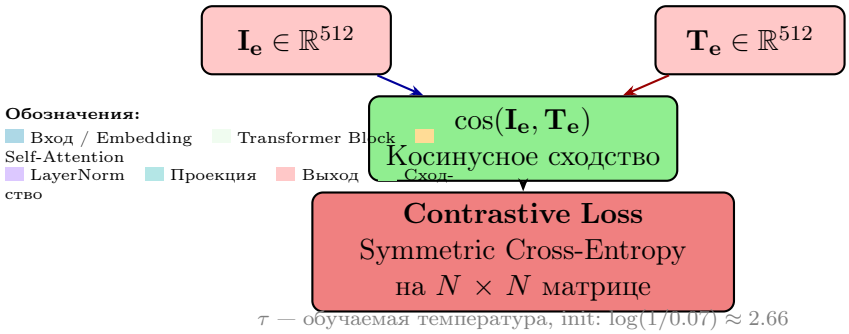

τ — обучаемая температура, init: $\log(1/0.07) \approx 2.66$

Zero-Shot Classification: пайплайн инференса

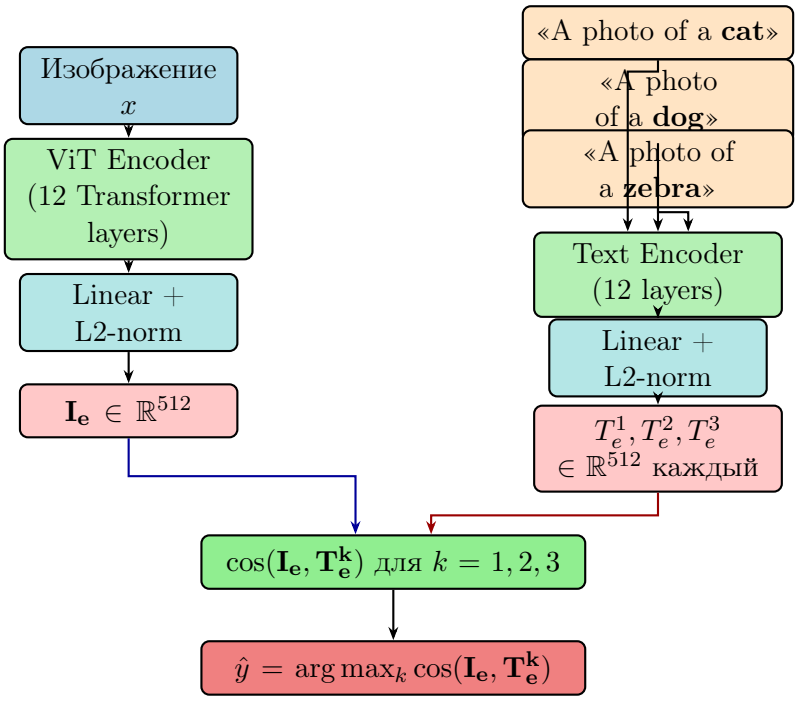

Предсказание: «cat»

Структура одного Transformer Block

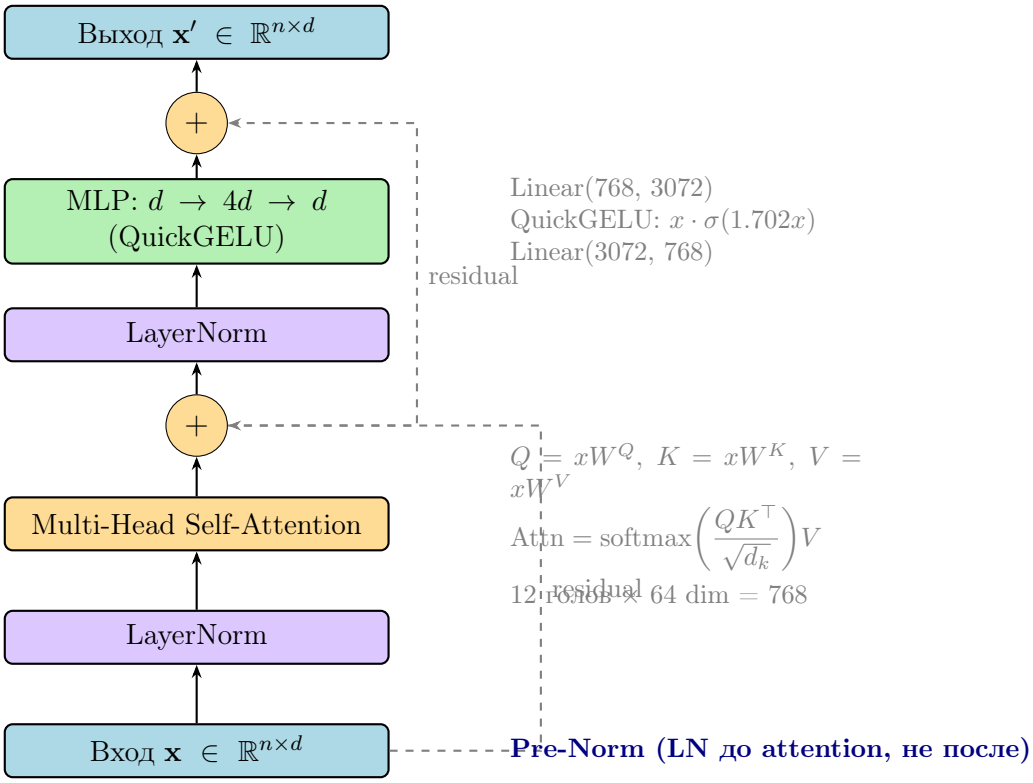

Варианты моделей CLIP

Модель	Patch	Слоёв	Heads	Width	Params (vis.)	ImageNet ZS
ViT-B/32	32×32	12	12	768	∼86M	63.2%
ViT-B/16	16×16	12	12	768	∼86M	68.3%
ViT-L/14	14×14	24	16	1024	∼304M	75.3%
ViT-L/14@336	14×14	24	16	1024	∼304M	**76.2%**

Текстовый энкодер (для ViT-B/32): 12 слоёв, ширина 512, 8 голов, ∼63M параметров, vocab = 49 408 (BPE), max_length = 77. Каузальная маска (decoder-only, как GPT).

Поток размерностей: Image Encoder

$$\underbrace{224\times224\times3}_{\text{RGB}} \xrightarrow{\text{Conv2d(3,768,32,32)}} \underbrace{[49,768]}_{\text{49 патчей}} \xrightarrow{\text{+[CLS]+PE}} \underbrace{[50,768]}_{\text{50 токенов}}$$

$$\xrightarrow{12\times\text{Transformer}} [50,768] \xrightarrow{\text{[CLS]}} \underbrace{[768]}_{\text{вектор}} \xrightarrow{W_v} [512] \xrightarrow{\ell_2} \boxed{\mathbf{I_e} \in \mathbb{R}^{512}}$$

Поток размерностей: Text Encoder

$$\text{«A photo of a cat»} \xrightarrow{\text{BPE}} \underbrace{[77]}_{\text{токены}} \xrightarrow{\text{Emb+PE}} \underbrace{[77,512]}_{\text{эмбеддинги}}$$

$$\xrightarrow{12\times\text{MaskedTransf.}} [77,512] \xrightarrow{\text{[EOS]}} \underbrace{[512]}_{\text{вектор}} \xrightarrow{W_t} [512] \xrightarrow{\ell_2} \boxed{\mathbf{T_e} \in \mathbb{R}^{512}}$$

Контрастивный Loss (InfoNCE)

Батч из N пар. Матрица сходства $N \times N$:

$$\text{logits}_{ij} = \cos(\mathbf{I_e}^{(i)}, \mathbf{T_e}^{(j)}) \cdot \exp(\tau)$$

$$\boxed{\mathcal{L} = \frac{1}{2}\left[\underbrace{\text{CE}(\text{logits}, \text{labels}, \text{rows})}_{\text{image}\to\text{text}} + \underbrace{\text{CE}(\text{logits}, \text{labels}, \text{cols})}_{\text{text}\to\text{image}}\right]}$$

$\text{labels} = [0, 1, \ldots, N-1]$, τ — обучаемый скаляр.

Псевдокод (из статьи):

```
I_f = image_encoder(I)          # [n, d_i]
T_f = text_encoder(T)           # [n, d_t]
I_e = l2_normalize(I_f @ W_i)   # [n, d_e]
T_e = l2_normalize(T_f @ W_t)   # [n, d_e]
logits = I_e @ T_e.T * exp(t)   # [n, n]
labels = arange(n)
loss_i = cross_entropy(logits, labels, axis=0)
loss_t = cross_entropy(logits, labels, axis=1)
loss   = (loss_i + loss_t) / 2
```

CLIP vs SigLIP: отличие в Loss

	CLIP (Softmax / InfoNCE)	**SigLIP (Sigmoid)**
Формула	$\mathrm{CE}(\mathrm{softmax}(\mathrm{logits}), \mathrm{labels})$	$-\sum_{ij} \log \sigma(z_{ij} \cdot s_{ij})$
Нормализация	Глобальная (по всему батчу)	Независимая (каждая пара)
Батч	Нужен большой (32K)	Работает при любых размерах
ImageNet ZS	76.2% (ViT-L/14@336)	Превосходит CLIP

$z_{ij} = +1$ если пара совпадает, -1 иначе. $s_{ij} = \tau \cdot \cos(\mathbf{I_e}^{(i)}, \mathbf{T_e}^{(j)}) + b$.