Архитектуры ZSL/FSL: все схемы

Приложение к учебному гайду

Схема 1. DeViSE (Frome et al., NeurIPS 2013)

Проекция CNN-признаков в пространство Word2Vec через обучаемую линейную трансформацию.

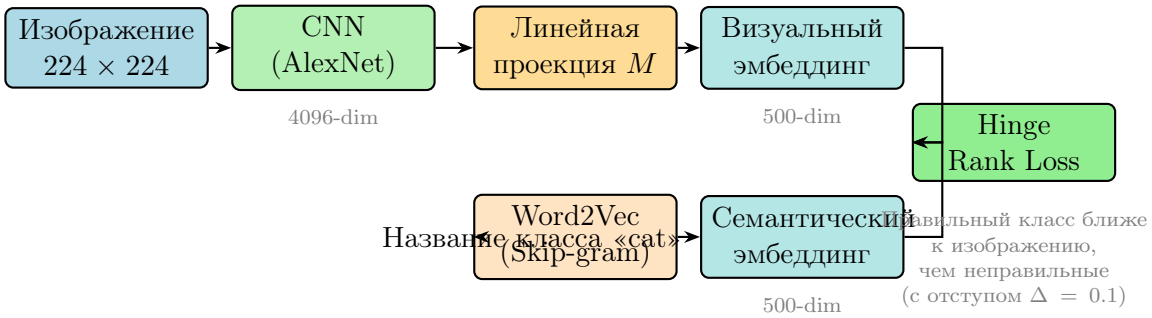

$$L = \sum_{j \neq y} \max\Big[0,\ \Delta - \tilde{t}_y \cdot M\bar{v}(x) + \tilde{t}_j \cdot M\bar{v}(x)\Big]$$

где $\tilde{t}_y$ — Word2Vec эмбеддинг правильного класса, $M\bar{v}(x)$ — спроецированные CNN-признаки.

Схема 2. f-CLSWGAN (Xian et al., CVPR 2018)

Условный WGAN генерирует синтетические CNN-признаки для unseen-классов.

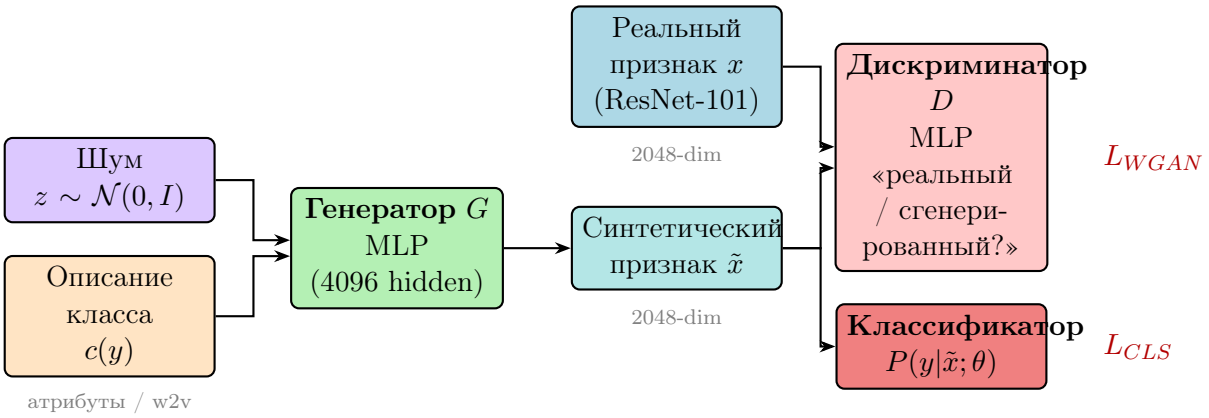

Полная функция потерь:

$$\min_G \max_D \; L_{WGAN} + \beta \cdot L_{CLS}, \quad \beta = 0.01,$$

$\lambda = 10$

Схема 3. DAP Pipeline (Lampert et al., CVPR 2009)

Предсказание класса через промежуточные атрибуты.

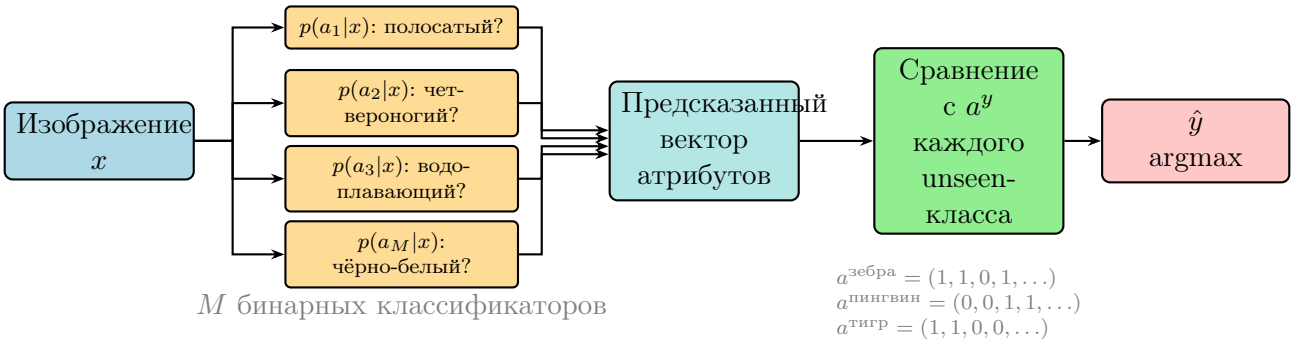

$$\hat{y} = \arg \max_{y \in Y_{unseen}} \sum_{m=1}^{M} \left[a_m^y \cdot \log p(a_m|x) + (1 - a_m^y) \cdot \log(1 - p(a_m|x)) \right]$$

Схема 5. OWL-ViT (Minderer et al., ECCV 2022)

Адаптация CLIP для zero-shot object detection: каждый patch-токен = потенциальный объект.

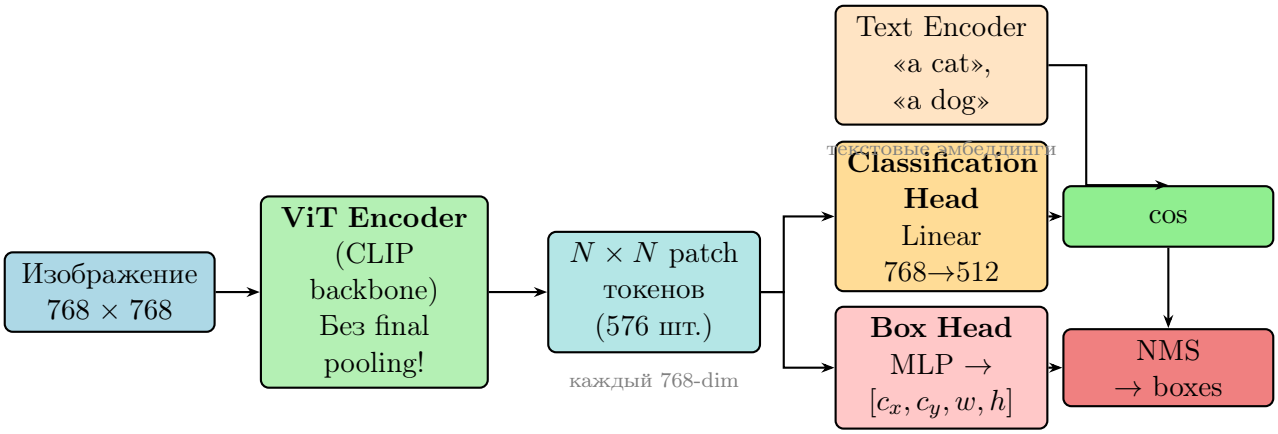

Ключевое отличие от CLIP: CLIP берёт [CLS]-токен → один вектор на всё изображение.
OWL-ViT использует **все patch-токены** → каждый патч = потенциальный объект.
К каждому токену прикреплены Classification Head (cos с текстом) + Box Head (→ bbox).

Схема 6. Siamese Networks (Koch et al., ICML Workshop 2015)

Две одинаковые CNN с общими весами определяют, принадлежат ли два изображения одному классу.

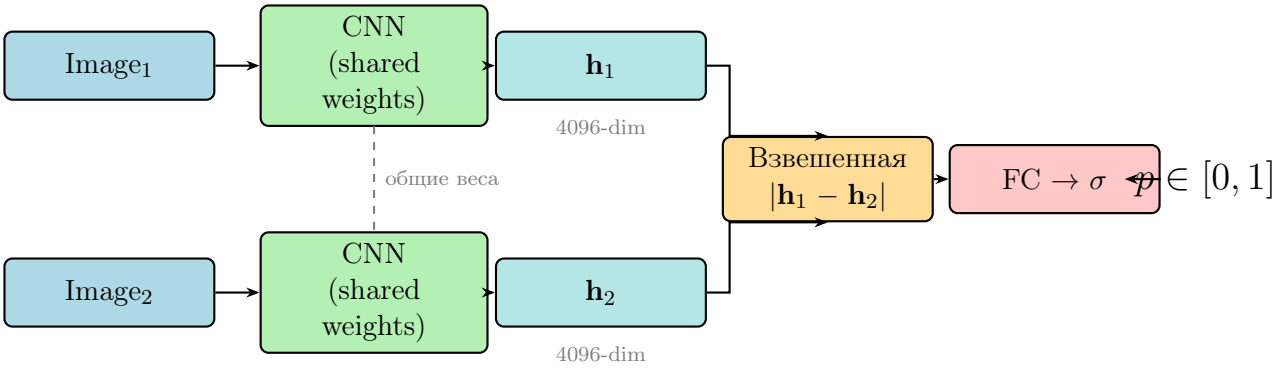

$$p(x_1, x_2) = \sigma\left(\sum_j \alpha_j \cdot |h_1^{(j)} - h_2^{(j)}|\right) \qquad L = y \cdot \log p + (1 - y) \cdot \log(1 - p)$$

α_j — обучаемый вес j-й компоненты; $y = 1$ если один класс, $y = 0$ если разные.

Схема 7. Matching Networks (Vinyals et al., NeurIPS 2016)

Классификация через взвешенное голосование по support set с attention.

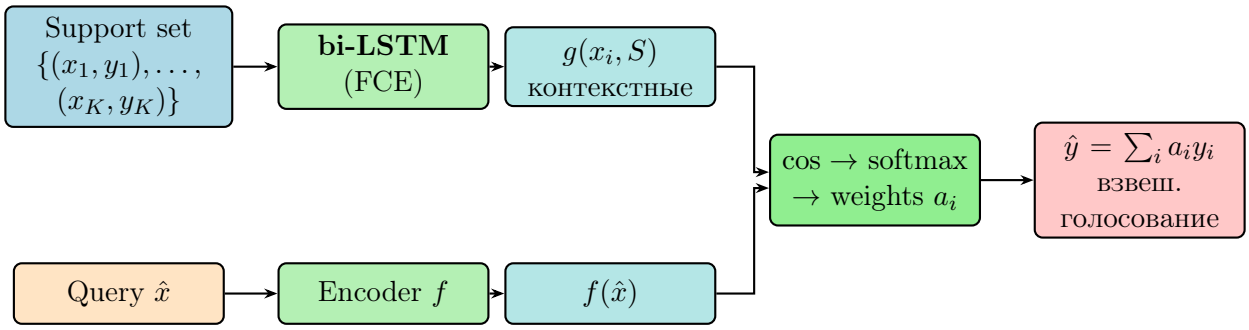

$$a(\hat{x}, x_i) = \frac{\exp\big(\cos(f(\hat{x}),\ g(x_i, S))\big)}{\sum_j \exp\big(\cos(f(\hat{x}),\ g(x_j, S))\big)} \qquad \hat{y} = \sum_{i=1}^{K} a(\hat{x}, x_i) \cdot y_i$$

$g(x_i, S) = \overrightarrow{h}_i + \overleftarrow{h}_i + g'(x_i)$ — Full Context Embedding через bi-LSTM.

Схема 8. Prototypical Networks (Snell et al., NeurIPS 2017)

Прототип = среднее эмбеддингов support-примеров. Классификация по ближайшему прототипу.

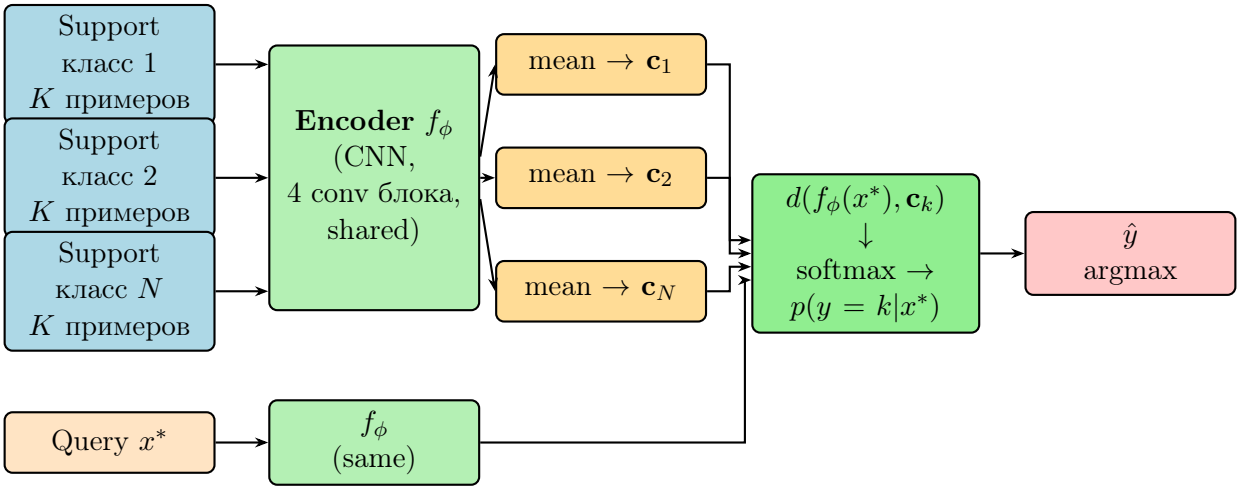

$$\mathbf{c}_k = \frac{1}{|S_k|} \sum_{(x_i, y_i) \in S_k} f_\phi(x_i) \qquad p(y{=}k \mid x^*) = \frac{\exp(-d(f_\phi(x^*), \mathbf{c}_k))}{\sum_{k'} \exp(-d(f_\phi(x^*), \mathbf{c}_{k'}))}$$

d — евклидово расстояние (дивергенция Брэгмана для $\varphi(z) = \|z\|^2$).

Схема 9. MAML (Finn et al., ICML 2017)

Мета-обучение инициализации через двухуровневую оптимизацию.

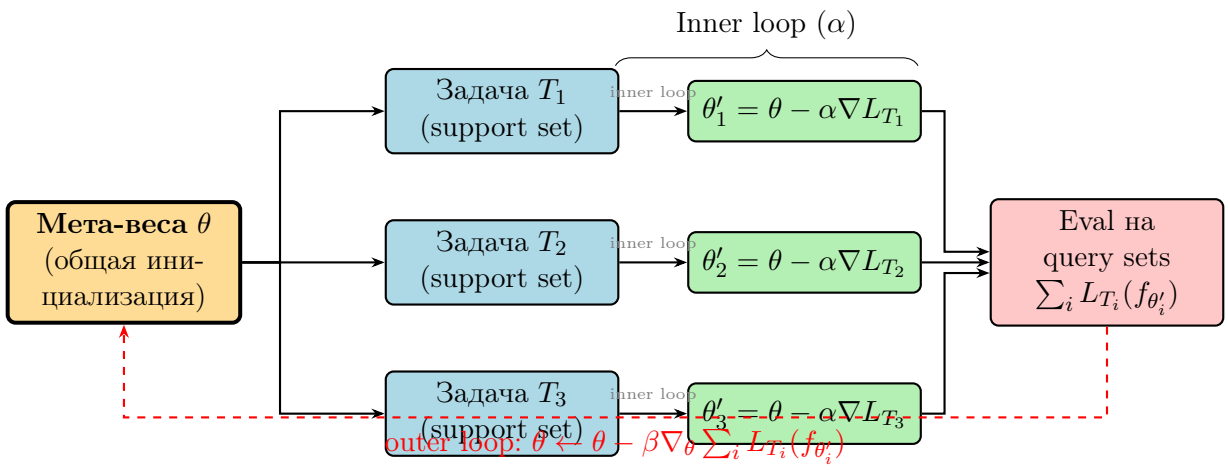

Inner: $\theta'_i = \theta - \alpha \nabla_\theta L_{T_i}(f_\theta)$ — адаптация к задаче

Outer: $\theta \leftarrow \theta - \beta \nabla_\theta \sum_{T_i} L_{T_i}(f_{\theta'_i})$ — мета-оптимизация

Схема 10. SetFit (Tunstall et al., 2022)

Двухэтапный few-shot: контрастивное дообучение Sentence Transformer + классификационная голова.

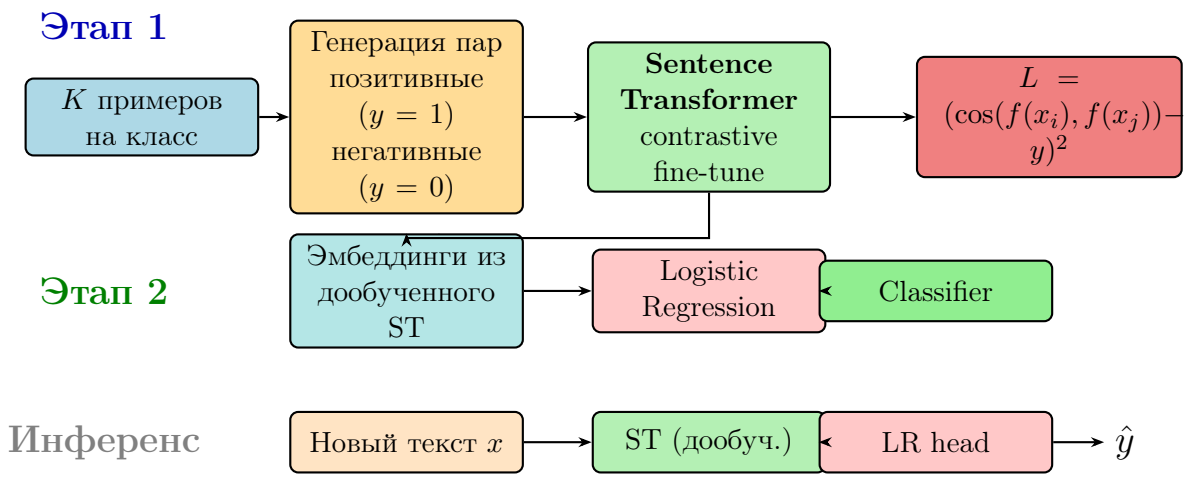

Результат: SetFit (∼355M) **превосходит** GPT-3 (175B) на RAFT: 71.3% vs 62.7%.

Схема 11. LoRA (Hu et al., ICLR 2022)

Низкоранговое разложение обновления весов: $W = W_0 + BA$, $r \ll \min(d, k)$.

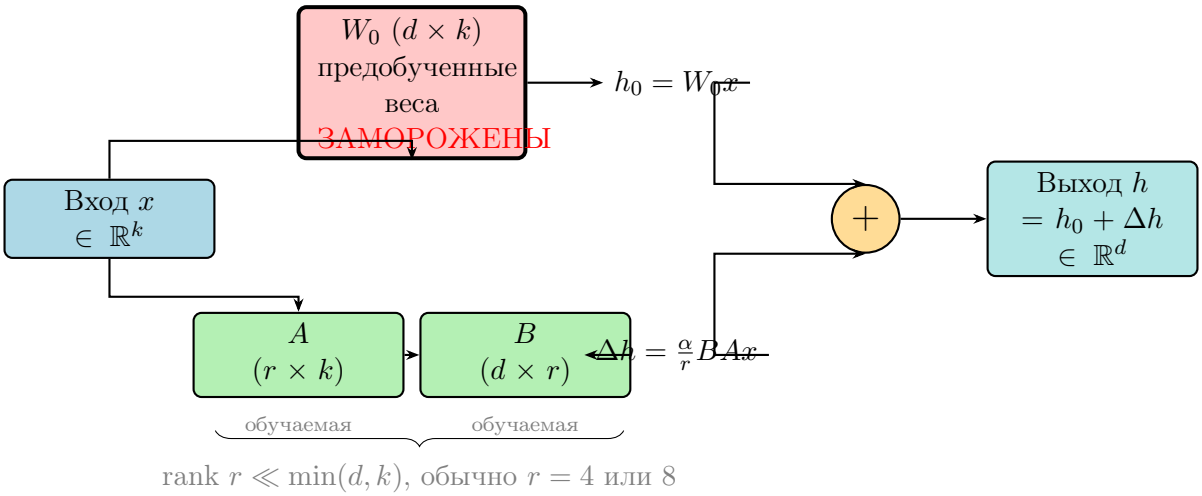

Init: $A \sim \mathcal{N}(0, \sigma^2)$, $B = 0 \Rightarrow \Delta W = 0$ в начале (старт = предобученная модель).
Инференс: $W = W_0 + BA$ вычисляется явно **один раз** $\Rightarrow$ нулевая дополнительная задержка.
GPT-3 (175B): обучаемых параметров в **10 000**$\times$ меньше, GPU-памяти в **3**$\times$ меньше.

$$\boxed{W = W_0 + \Delta W = W_0 + BA, \quad B \in \mathbb{R}^{d \times r},\ A \in \mathbb{R}^{r \times k},\ r \ll \min(d, k)}$$